

MODELAGEM INFORMACIONAL


Arquiteturas Zaloni e Inmon



-Data Lake, arquiteturas

REFERÊNCIAS

- *Sharma, B. (2018).
Architecting Data Lakes.
O'Reilly Media, Inc.
<http://www.oreilly.com/data/free/architecting-data-lakes.csp>*



Data Lake Zaloni

A stack (“pilha”) de soluções de um Data Lake




Figure 2-1. The data lake technology stack

Nuvem vs on-premises

TCO Calculator

Compare Total Cost of Ownership of MCP OpenStack vs. AWS EC2.

Scale

Number of Clouds/Regional Data Centers



Compute


Initial VM Count



Avg. Annual Cloud Growth Rate Over 4 Years



Number of VMs over time



AWS vs OpenStack Cost comparison



Avg. TCO/VM/yr over 4 years

AWS	\$2,391
OpenStack	\$2,264


Total Savings \$288,762

The complete TCO model includes over 50 variables and dependencies, such as hardware configuration assumptions, electricity and data center costs, IT staffing costs, network and storage requirements etc. Click below to download the full TCO model in Microsoft Excel format.

[ACCESS FULL TCO CALCULATOR](#)


Armazenamento e retenção

Arquitetura on-premises



Armazenamento e retenção

Arquitetura on-premises mais recente



Armazenamento e retenção

Arquitetura na nuvem

Amazon S3 > dlzagi > Editar versionamento de bucket

Editar versionamento de bucket [Info](#)

Versionamento de bucket

O versionamento é um meio de manter múltiplas variantes de um objeto no mesmo bucket. Você pode usar o versionamento para preservar, recuperar e restaurar todas as versões de cada objeto armazenado no bucket do Amazon S3. Com o versionamento, você pode recuperar facilmente ações não intencionais do usuário e falhas da aplicação. [Saiba mais](#) 

Versionamento de bucket

☐ Suspendar


Essa ação suspende a criação de versões de objeto para todas as operações, mas preserva as versões existentes dos objetos.

☒ Ativar

 Depois de habilitar o versionamento de bucket, talvez seja necessário atualizar suas regras de ciclo de vida para gerenciar versões anteriores de objetos.

Computação

Map Reduce, Apache Hive, AWS Athena, Apache Spark




Aplicação

A visualização é uma parte importante desta fase, onde os dados são transformados em tabelas e gráficos para facilitar a compreensão.

Map representing the losses over time of French army troops during the Russian campaign, 1812-1813.
Constructed by Charles Joseph Minard, Inspector General of Public Works retired.

Paris, 20 November 1869

The number of men present at any given time is represented by the width of the grey line; one mm. indicates ten thousand men. Figures are also written besides the lines. Grey designates men moving into Russia; black, for those leaving. Sources for the data are the works of messrs. Thiers, Segur, Fezensac, Chambray and the unpublished diary of Jacob, who became an Army Pharmacist on 28 October. In order to visualize the army's losses more clearly, I have drawn this as if the units under prince Jerome and Marshall Davoust (temporarily separated from the main body to go to Minsk and Mikilow, which then joined up with the main army again), had stayed with the army throughout.



Editor's note: dates & temperatures are only referenced for the retreat from Moscow

© 2001, ODT Inc. All rights reserved.

Figure 58. Minard's map of Napoleon's Russian campaign.

This graphic has been translated from French to English and modified to most effectively display the temperature data.

Arquitetura “Zaloni” de Data Lake

A arquitetura Zaloni foca em questões operacionais, sobre como o Data Lake é gerenciado.

A abordagem recomenda organizar o data lake em quatro zonas e uma sandbox. Em todas as zonas, os dados são rastreados, validados, catalogados, os metadados atribuídos e refinados. Esses recursos e as zonas em que ocorrem os processamentos ajudam os usuários e moderadores a entender em que estágio os dados estão e quais medidas foram aplicadas a eles até o momento. Os usuários podem acessar os dados em qualquer uma dessas zonas, desde que tenham acesso baseado em função apropriada.




Figure 2-2. The Zaloni data lake reference architecture outlines best practices for storing, managing, and governing data in a data lake

As zonas da arquitetura “Zaloni”

Sandbox

Permite a análise exploratória sobre todas as zonas do Data Lake sem a necessidade de envolver o departamento de TI ou de dedicar fundos para a criação de ambientes adequados para testar os dados.

Evidente que os acessos específicos de cada gestor ou analista são pré-determinados por uma instância superior na organização.

Transiente

Camada temporária “transiente landing zone”, usada apenas para a primeira carga e checagens de segurança e políticas da empresa. Ex. GDPR e LGPD.

Zona bruta

Depois das checagens de qualidade e transformações de segurança inicia-se a jornada no data lake. Aqui o dado é armazenado e catalogado de forma permanente.

Zona confiável

Os dados foram pré-processados e validados. Ex.: se o mesmo cliente aparece em 5 sistemas distintos, aqui ele possui apenas um registro que o representa integralmente (MDM).

Zona refinada

Os dados foram formatados para facilitar o uso geral e/ou atender uma linha específica de negócio. Novas checagens de qualidade também podem ser feitas.

Governança do Data Lake

O Data Lake pode atender casos ad hoc, mas sem governança dificilmente haverá confiança no Data Lake para entrega de produtos essenciais de negócio.

Qualidade e consistência

O que é necessário para garantir que os dados sejam de qualidade e consistência suficientes para serem úteis aos usuários de negócios e cientistas de dados?

Políticas e padrões

Quais são as políticas e padrões para ingestão, transformação e uso de dados, e elas são observados de maneira uniforme em toda a organização?

Segurança e conformidade

O acesso a dados confidenciais é limitado àqueles com a devida autorização?

Gestão do ciclo de vida do dado

Como gerenciaremos o ciclo de vida dos dados? Em que ponto os dados serão movidos para camadas de armazenamento mais baratos (arquivamento)?

Gerando valor a partir do Data Lake

Autonomia ...

O consumo via autoatendimento é essencial para um Data Lake bem-sucedido. Diferentes tipos de usuários consomem os dados e procuram coisas diferentes, mas cada um deseja acessar os dados de maneira autônoma, sem a ajuda de TI.

...via autosserviço...

A Plataforma de autoatendimento precisa ser organizada de forma a prover um "uso guiado" aos diversos usuários, para que seja uma experiência simples e útil.

...para todos os públicos.

O executivo, o cientista de dados, o analista de negócio, e inclusive outros sistemas, como por exemplo um Data Warehouse lendo um Data Lake como uma fonte de dados.

Plataforma de autosserviço

Responder a essas perguntas requer que a arquitetura, governança e regras de segurança adequadas sejam implementadas e respeitadas, para que as pessoas apropriadas tenham acesso aos dados relevantes em tempo hábil. Também é necessário haver uma governança rígida na integração de conjuntos de dados, convenções de nomenclatura devem ser estabelecidas e aplicadas e políticas de segurança devem estar em vigor para garantir o controle de acesso baseado em funções.

O objetivo de um Data Lake é fornecer valor aos negócios atendendo aos usuários.

Da perspectiva do usuário, seguem algumas perguntas que precisam de respostas claras desde o início.

O que há no Data Lake (o catálogo)?


Qual é a qualidade dos dados?

Qual é o perfil dos dados?

Quais são os metadados dos dados?

Como os usuários podem fazer enriquecimentos, limpezas, melhorias e agregações sem precisar da TI (como usar o Data Lake de forma self-service)?

Como os usuários podem anotar e marcar os dados?



Controle de acesso



Com as políticas de segurança em vigor, os usuários têm acesso apenas aos conjuntos de dados atribuídos a seus níveis de privilégio.

Os Data Lakes precisam permitir que vários usuários de vários departamentos usem as ferramentas de que precisam e descubram insights através das relações entre os conjuntos de dados. Isso é um desafio de segurança.

Definir e aplicar as políticas de segurança de forma consistente é essencial para o uso bem-sucedido de um Data Lake.

Um relatório gerado para um executivo pode ser muito confidencial e não deve estar disponível para outras pessoas que não tenham os mesmos privilégios de acesso. Os cientistas de dados podem precisar de mais flexibilidade, com menores níveis de governança; para este grupo, você pode criar uma sandbox para trabalho exploratório. Da mesma forma, os usuários do departamento de marketing de uma empresa não devem ter acesso aos mesmos dados que os usuários do departamento financeiro.



Estratégia de governança (crowdsourcing)




Uma abordagem bottom-up para a governança de dados permite que você classifique a utilidade dos conjuntos de dados de acordo com a visão dos próprios usuários, o que pode se mostrar muito produtivo.

Para usar essa estratégia, é necessário que o catálogo possua um mecanismo de classificação (tagging) como parte integrada do Data Lake.

Os usuários também precisam de ferramentas para criar novos modelos de dados a partir de conjuntos de dados existentes. O que sair de útil ao negócio desses novos modelos seria o "enriquecimento". O aumento do valor para o negócio.

Checklist para um Projeto de Data Lake



Lista de Prioridades orientada aos benefícios para Negócios

É preciso ter um alinhamento muito forte com as necessidades atuais e futuras da empresa. Afinal, o Data Lake precisa fornecer valor para além do DW. Isso pode ser resolvendo pontos problemáticos ou criando novos fluxos de receita líquidos que você pode permitir que as equipes de negócios entreguem. Ser capaz de definir e articular esse valor do ponto de vista de negócios e convencer os parceiros a acompanhá-lo na jornada é muito importante para o seu sucesso.

Arquitetura

Quais são os diferentes componentes de que você precisará e como será a plataforma técnica final?

Trata-se de um investimento de longo prazo, por isso é importante conhecer cuidadosamente sobre a tecnologia escolhida. Como fazer?

As Provas de Conceito (POC) são ótimos instrumentos para encontrar as respostas iniciais.

Uma boa estratégia de governança de dados, metadados, e coleta é crítica para construir um Data Lake gerenciado e governado em vez do tão difamado "pântano de dados".

Estratégia de segurança

A privacidade e a segurança dos dados são críticas, especialmente para dados confidenciais, como informações de saúde protegidas e informações de identificação pessoal.

Os dados que podem ter sido protegidos antes como resultado do isolamento físico agora estão disponíveis no Data Lake. Você pode ter regras regulatórias com as quais precisa estar em conformidade.

Se você estiver atendendo a públicos externos, cada cliente pode ter acordos de dados individuais, que precisam ser honrados.

Checklist para um Projeto de Data Lake



Modelo de escalonamento

Existem modelos de Plataformas como Serviço na nuvem que permitem isolar os custos entre armazenamento e processamento do Data Lake. (Já vimos S3 + Athena).

Existem modelos em que o uso de equipamentos antigos podem ser usados em grid, ao invés de serem inativados.

Faz parte do projeto simular esses diferentes cenários através de provas de conceito, sempre levando em conta os custos de cada cenário e o tipo de uso que será feito pelos usuários.

Skill da equipe de trabalho

Para que qualquer projeto de Data Lake seja bem-sucedido, as pessoas certas são necessárias. Engenheiros de dados, cientistas de dados, administradores de dados, além pessoas com perfis de segurança da informação, gestão e governança de dados.

Plano de operações

Uma vez que o Data Lake seja incorporado como um novo serviço disponível, é necessário estabelecer um acordo de serviço com os usuários (SLA). Assim como ter um Sistema de alerta e monitoração e um time especializado na gestão do ambiente, priorizando os requisitos de negócio.

Checklist para um Projeto de Data Lake



Plano de contingência

Esse item não se aplica apenas ao Data Lake. Um plano de continuidade de negócio precisa levar em conta a empresa como um todo, preparando-a para estar blindada na decorrência de desastres naturais ou sabotagens.

Um plano de contingência geralmente leva em conta três grandes pilares: hardware, software e “*humanware*”. Contando com processos documentados, testados e atualizados.

Plano de comunicações

O sucesso do Data Lake também depende da aderência de toda a companhia.

Dado o “novo paradigma”, pode ser necessário organizar seminários e oficinas, apresentando os casos de sucesso que já beneficiaram o negócio, buscando sempre impulsionar o crescimento orgânico da Data Lake.

Visão de cinco anos

Um ambiente de Data Lake, assim como um DW e os ambientes de bancos de dados transacionais, são como grandes navios cargueiros em uma empresa. Os movimentos são lentos e afetam a todos.


Movimentos apressados ou mal calculados podem resultar em um efeito muito negativo.

É bom que a inovação ocorra a partir de provas de conceito realizadas junto com a área de negócio, representada por usuários chave.

Inmon DL

REFERÊNCIAS

- *Bill Inmon. Data Lake Architecture: Designing the Data Lake and Avoiding the Garbage Dump.*



O cientista de dados segundo Inmon

Quando um Data Lake está em seu estado bruto, apenas poucos especialistas conseguem extrair algo de útil, tipicamente essas pessoas são chamadas de cientistas de dados.

Difícil de encontrar para contratar

Iniciativas como esta graduação da EMAP estão diminuindo esta dificuldade.

Contratação cara

A escassez de profissionais eleva naturalmente os salários.

Difícil de encontrar depois de contratado

Uma vez contratado, o cientista de dados é muito requisitado, dificultando o avanço dos projetos de ciência de dados na empresa.

Data Lake para uso geral



Imagine um Data Lake em que apenas uma quantidade reduzida de pessoas super ocupadas podem operar. A extração de valor fica muito limitada.

Agora imagine o que ocorre em um Data Lake onde diversos usuários de negócio conseguem interagir e gerar valor ao negócio. Chegamos em outro nível de maturidade.

Alguns ingredientes básicos podem contribuir para um uso mais democrático do Data Lake, conforme abaixo.

Metadados

Usado para decifrar os dados encontrados no Data Lake.

Mapa de integração

Demonstra como os dados podem ser integrados no Data Lake. Como vencer os "silos" isolados de dados.

Contexto

A capacidade de estabelecer relações entre os diversos tipos de dados depende de um contexto.

"Metaproceto"

A credibilidade dos dados depende, em parte, da capacidade de rastrear tudo o que for pertinente a geração dos dados.

Por dentro do Data Lake

Para melhor compreender como o Data Lake pode ser preparado para uso futuro, é necessário dar uma olhada no que se coloca dentro de um Data Lake. Veja abaixo os três principais tipos de dados.



Dados analógicos

Dados de telemetria (e.g. GPS), dados gerados por máquinas. Desde log de reatores nucleares até o uso de CPU de um celular.

Em geral, são dados volumosos e repetitivos. Tipicamente, apenas os outliers são alvo de interesse.

Dados de aplicação

São os dados gerados a partir da execução de uma aplicação ou transação, e enviados ao Data Lake.

Quando qualquer evento relevante ao negócio ocorre, o evento é medido através da aplicação e o dado é criado. Estrutura uniforme. E.g. prever separação do casal.

Dados textuais

Também está ligado a aplicação, contudo não possui estrutura uniforme.

Esse dado é chamado de "não-estruturado" porque pode assumir qualquer forma.

Algumas ferramentas: GATE e Doccano.

Dados analógicos

Monitoração de servidores em uma empresa.

Name	Last check ▲	Last value	Change
CPU (3 Items)			
Processor load (15 min average)	2021-10-29 14:32:44	0.0008	
Processor load (1 min average)	2021-10-29 14:32:45	0	
Processor load (5 min average)	2021-10-29 14:32:46	0.0008	
Filesystems (6 Items)			
Espaço livre em disco no E:	2021-10-29 14:28:55	1.39 TB	
Espaço livre em disco no E: (percentage)	2021-10-29 14:28:57	14.23 %	
Espaço total em disco no E:	2021-10-29 14:28:59	9.77 TB	
Espaço em disco usado E:	2021-10-29 14:29:01	8.38 TB	
File read bytes per second	2021-10-29 14:32:38	12.09 KBps	+7.9 KBps
File write bytes per second	2021-10-29 14:32:39	35.36 Bps	-0.45 Bps
General (1 Item)			
System uptime	2021-10-29 13:28:49	273 days, 06:51:44	+06:00:00
ICMP (3 Items)			
ICMP perdido	2021-10-29 14:32:20	0 %	
ICMP ping	2021-10-29 14:32:20	Up (1)	
ICMP tempo de resposta	2021-10-29 14:32:20	7.9ms	
Memory (6 Items)			
Total swap space	2021-10-29 14:28:48	18 GB	
Total memory	2021-10-29 14:28:52	8 GB	

Dados analógicos

Monitoração de uma plataforma de petróleo.




Fonte: <https://www.osul.com.br/a-petrobras-evacua-navio-em-plataforma-no-rio-de-janeiro-e-nega-risco-de-naufragio/>
<https://jovempan.com.br/noticias/petrobras-volta-convidar-para-licitacao-investigada-sbm-offshore.html>

Dados analógicos

Há uma compreensão de que determinada faixa de valores de indicadores revelam uma situação normal de operação. Esse processo de medição e avaliação de um indicador, é um metaprocesso.

Após essa compreensão, eventos que saem dos intervalos normais podem gerar alertas sobre serviços produtivos. A ideia é que ações de correção possam ser tomadas antes da interrupção do serviço.




404 ERROR


SORRY, THE PAGE NOT FOUND

Mais uma classificação: dados repetitivos vs dados não repetitivos

Dados não repetitivos



Dados repetitivos



Uma outra forma de classificação de dados é quanto ao padrão de repetição.

Dados repetitivos tornam-se de fácil absorção na medida em que já são conhecidos.

Dados não repetitivos significam um grau de atenção e cuidado maior, dada a sua aleatoriedade.

As lagoas do data lake (*data ponds*)

Para organizar os diferentes tipos de dados em uma estrutura que permita análise, é necessário criar uma estrutura de dados de alto nível dentro do Data Lake. Conforme os dados entram no lago, eles primeiro entram no reservatório de dados brutos. O objetivo do data pond bruto é servir como uma célula de retenção. Há pouca ou nenhuma análise ou outra atividade organizada dos dados enquanto estão na lagoa de dados brutos.



Estrutura geral dos Data Ponds

Cada data pond, exceto o de dados brutos, possui alguns componentes em comum.

The screenshot shows a file viewer interface for 'Omniiture.0.tsv.gz'. The file content is a TSV (Tab-Separated Values) format. Red arrows and boxes highlight specific components of the data rows:

- Registered User SWID (if logged in):** Points to the first column (e.g., 1331799426).
- Timestamp:** Points to the second column (e.g., 2012-03-15 01:17:06).
- IP Address:** Points to the third column (e.g., 99.122.210.248).
- Geocoded IP Address:** Points to the fourth column (e.g., 0).
- URL:** Points to the fifth column (e.g., http://www.acme.com/SH55126545/VD5517036).

The table content is as follows:

1331799426	2012-03-15 01:17:06	2860005755985467733	4611687631108657821	FAS-2.8-AS3
N 0	99.122.210.248	1 0	10	http://www.acme.com/SH55126545/VD5517036
4	{7AAB8415-E803-3C5D-7100-E362D7F67CA7}	U	en-us,en;q=0.5	516 575 1366 Y
N Y	2 0	304	sbcglobal.net	15/2/2012 4:16:0 4 240 45 41 10002,00
011,10020,00007	Mozilla/5.0 (Windows; U; Windows NT 6.1; en-US; rv:1.9.2)	Gecko/20100115	Firefox/3.6	
48 0	2 3	0	homestead usa 528 fl	0 0 0
0				

Pond descriptor

Contém uma descrição do conteúdo recebido: frequência de atualização, descrição da origem, volume de dados, critérios de seleção, critérios de sumarização, critérios de organização e descrição dos relacionamentos entre os dados.

Pond target

Trata-se do tema que irá moldar os dados para atingir objetivos de negócio, e.g. “perfil de cliente”, “registros de vendas”, “análise de click stream”. É o meio pelo qual é estabelecida a relação com o tema de negócio.

Pond data

Trata do mecanismo de armazenamento do pond. É comum usar “schema-on-read”, no entanto é bom observar o *trade-off*: facilidade gravar vs facilidade de ler os dados.

Estrutura geral dos Data Ponds

Cada data pond, exceto o de dados brutos, possui alguns componentes em comum.



Pond metadata

Características físicas dos dados no pond. Esse metadado é dependente do meio físico nativo do dado. E.g. se o dado veio de um SGBD, muitas dessas características serão herdadas no pond, tais como, chaves e índices.

Pond metaprocess

Descrição da transformação que é realizada nos dados brutos, para que tornem-se úteis aos analistas de negócio.


Também pode-se descrever processos que ocorreram antes do dado chegar no pond.

Pond transformation criteria

Descrição dos critérios usados no processo de transformação.

No caso dos dados analógicos poderia ser: "se a temperatura do tanque for maior do que 50°C, capture o registro", por exemplo.

As arquiteturas Zaloni vs Inmon



Zaloni

Leva em conta que o dado passa por estágios (zonas) de refinamento.

Inmon

Leva em conta os tipos de dados e prevê uma segregação arquitetônica de acordo.

Ambas abordagens apontam para a importância da governança, metadados e linhagem dos dados, evitando que o Data Lake se transforme num pântano.

Estrutura geral dos Data Ponds

Cada data pond, exceto o de dados brutos, possui alguns componentes em comum.

The screenshot shows a file viewer interface for 'Omniture.0.tsv.gz'. The file content is a TSV (Tab-Separated Values) format. Red arrows and boxes highlight specific components of the data rows:

- Registered User SWID (if logged in):** Points to the first column (e.g., 1331799426).
- Timestamp:** Points to the second column (e.g., 2012-03-15 01:17:06).
- IP Address:** Points to the third column (e.g., 99.122.210.248).
- Geocoded IP Address:** Points to the fourth column (e.g., 0).
- URL:** Points to the fifth column (e.g., http://www.acme.com/SH55126545/VD5517036).

The table content is as follows:

1331799426	2012-03-15 01:17:06	2860005755985467733	4611687631108657821	FAS-2.8-AS3
N 0	99.122.210.248	1 0	10	http://www.acme.com/SH55126545/VD5517036
4	{7AAB8415-E803-3C5D-7100-E362D7F67CA7}			
		U en-us,en;q=0.5	516 575	1366 Y
N Y	2 0	304 sbcglobal.net	15/2/2012 4:16:0 4 240 45	41 10002,00
011,10020,00007	Mozilla/5.0 (Windows; U; Windows NT 6.1; en-US; rv:1.9.2)	Gecko/20100115	Firefox/3.6	
48 0	2 3 0	homestead usa 528 fl	0 0 0	
0				

Pond descriptor

Contém uma descrição do conteúdo recebido: frequência de atualização, descrição da origem, volume de dados, critérios de seleção, critérios de sumarização, critérios de organização e descrição dos relacionamentos entre os dados.

Pond target

Trata-se do tema que irá moldar os dados para atingir objetivos de negócio, e.g. “perfil de cliente”, “registros de vendas”, “análise de click stream”. É o meio pelo qual é estabelecida a relação com o tema de negócio.

Pond data

Trata do mecanismo de armazenamento do pond. É comum usar “schema-on-read”, no entanto é bom observar o *trade-off*: facilidade gravar vs facilidade de ler os dados.

Estrutura geral dos Data Ponds

Cada data pond, exceto o de dados brutos, possui alguns componentes em comum.



Pond metadata

Características físicas dos dados no pond. Esse metadado é dependente do meio físico nativo do dado. E.g. se o dado veio de um SGBD, muitas dessas características serão herdadas no pond, tais como, chaves e índices.

Pond metaprocess

Descrição da transformação que é realizada nos dados brutos, para que tornem-se úteis aos analistas de negócio.


Também pode-se descrever processos que ocorreram antes do dado chegar no pond.

Pond transformation criteria

Descrição dos critérios usados no processo de transformação.

No caso dos dados analógicos poderia ser: "se a temperatura do tanque for maior do que 50°C, capture o registro", por exemplo.

As arquiteturas Zaloni vs Inmon



Zaloni

Leva em conta que o dado passa por estágios (zonas) de refinamento.

Inmon


Leva em conta os tipos de dados e prevê uma segregação arquitetônica de acordo.

Ambas abordagens apontam para a importância da governança, metadados e linhagem dos dados, evitando que o Data Lake se transforme num pântano.

REFERÊNCIAS

B. Inmon, M. Levins, and R. Srivastava, Building the Data Lakehouse. Technics Publications, 2021. Copyright © 2021 by Bill Inmon, Mary Levins, and Ranjeet Srivastava


Apresentação das figuras autorizadas pelo editor.



Data Warehouse

O data warehouse leva os dados operacionais para um outro local, evitando a concorrência com as bases voltadas para as transações do dia-a-dia da empresa. Assim, o data warehouse tornou-se um solução arquitetônica para um problema arquitetônico.

As limitações dos data warehouses tornaram-se evidentes com a crescente variedade de dados (texto, IoT, imagens, áudio, vídeos, drones, etc.) na empresa. Além disso, a ascensão de Aprendizado de Máquina (ML) e Inteligência Artificial (IA) introduziu algoritmos iterativos que exigiam dados não baseados em SQL.




Data Lake

O DL comporta vários tipos de dados, inclusive os estruturados. Um dos maiores desafios em um DL é que a forma e a estrutura de alguns dados é muito diferente dos dados tradicionais de um data warehouse. Para complicar a situação, os volumes de dados entre os diversos tipos de dados encontrados nos data lake são muito diferentes.

As organizações rapidamente descobriram que usar os dados no data lake era uma história completamente diferente do que apenas ter os dados disponíveis no lake. Dito de outra forma, as necessidades do usuário final eram muito diferentes das necessidades do cientista de dados. O usuário final encontra todos os tipos de obstáculos:

- Onde estão os dados necessários?
- Como uma unidade de dados se relaciona com outra unidade de dados?
- Os dados estão atualizados?
- Quão precisos são os dados?



Data Lakehouse

Do pântano de dados, emerge uma nova classe de arquitetura de dados chamada data lakehouse, com os seguintes componentes:


Dados do ambiente estruturado

Dados do ambiente textual

Dados do ambiente analógico/IoT


Uma infra-estrutura analítica que permite a leitura e a compreensão

Trata-se de um novo design de sistema aberto e padronizado que permite a análise de dados analógicos/IoT implementando estruturas e recursos de gerenciamento de dados similares àqueles encontrados em um data warehouse, mas operando diretamente no tipo de armazenamento de baixo custo usado para data lakes.



Data Lake na nuvem

Serviços da AWS para gerenciar a movimentação e a governança de dados



Teorema CAP

O teorema CAP


*O Teorema CAP, proposto por Eric Brewer, é um princípio fundamental no design de sistemas distribuídos, estabelecendo que é impossível garantir simultaneamente **Consistência**, **Disponibilidade** e Tolerância via Partições.*

Origem: Formalizado por Eric Brewer (2000) e comprovado por Gilbert e Lynch (2002).


Premissa: Sistemas distribuídos só podem garantir dois dos três pilares simultaneamente.

Analogia: "Bom, rápido e barato: escolha dois"


Consistency



Availability




Partition Tolerance



https://medium.com/@gurpreet.singh_89/understanding-the-cap-theorem-consistency-availability-and-partition-tolerance-e7faa5103638

<https://www.infoq.com/articles/cap-twelve-years-later-how-the-rules-have-changed/>



Considerações para Engenharia de Dados

Tolerância a Partições é obrigatória em sistemas distribuídos modernos.

BASE vs. ACID:

BASE (Basic Availability, Soft state, Eventual consistency) é o modelo adotado por sistemas AP.

ACID (Atomicity, Consistency, Isolation, Durability) é usado em sistemas CP.

Estratégias híbridas:

Combinação de bancos CP e AP para cobrir diferentes necessidades (ex: cache + banco principal).

Modelo operativo para pesquisa na FGV

Ciclo de vida padrão de pesquisas acadêmicas e participação no modelo operativo da FGV

