


MODELAGEM INFORMACIONAL

Big Data





- Big Data**
- Data Lake**

INTRODUÇÃO

- *Categorias macro de grandes conjuntos de dados corporativos:*
 - *Conjuntos de dados em **Bancos Operacionais***
 - *Conjuntos de dados em **Data Warehouse***
 - *Conjuntos de **Big Data***

INTRODUÇÃO

- *Exemplos de fontes que geram grandes quantidades de dados:*
 - *Smartphones que transmitem sua localização a cada poucos segundos*
 - *Chips embutidos em carros que realizam milhares de testes de diagnóstico por segundo*
 - *Câmeras que gravam continuamente espaços públicos e privados*
 - *Etiquetas de identificação por radiofrequência (RFID) que enviam um sinal sem fio que é lido em vários pontos conforme os carrinhos de mercadoria aos quais as etiquetas RFID estão fixadas viajam na cadeia de abastecimento do fabricante ao cliente*

Instrumentos gerando dados: um exemplo

No início, 1903, voava-se praticamente sem instrumentos.

Se havia algum dado coletado, provavelmente era “inferido” pelo piloto e anotado em papel.



Instrumentos gerando dados: um exemplo

Depois de 15 anos vemos alguns instrumentos básicos, que respondiam as questões mais críticas: qual a distância do solo, qual a velocidade, quanto há de combustível.



Instrumentos gerando dados: um exemplo

E os avanços continuaram. Em 1940 já era possível determinar a localização geográfica e comunicar-se via rádio. A cada vez mais instrumentos se tornaram disponíveis, dando cada vez mais recursos ao piloto. E conseqüentemente cada vez mais itens no cockpit (+300). O que aparentemente “ajudou”, trouxe outro problema: o piloto precisava saber ler e interpretar cada um dos 300 marcadores.



Instrumentos gerando dados: um exemplo

Podemos imaginar que com o avanço contínuo já deveríamos ter +500 marcadores. No entanto, a complexidade foi simplificada, atualmente um piloto vê 46 painéis, que em si conseguem agregar vários marcadores.

“A simplicidade é a maior sofisticação” (S.Jobs)

Hoje vemos cada vez mais dados cobrindo cada vez mais assuntos. O desafio é transpor a complexidade e extrair algum sentido a partir de tantos dados.



BIG DATA

- **Big data**

- *Conjuntos de dados em corporações e organizações que contêm **grandes volumes de dados diversificados e em rápido crescimento** que, ao contrário de bancos de dados operacionais e data warehouses, **não são modelados formalmente para consulta e recuperação e não são acompanhados de metadados detalhados***

BIG DATA

▪ *Big data*

- *Tipicamente não-estruturado ou semi-estruturado*
- *Dado não-estruturado*
 - **Sem estrutura explícita**
 - **e.g. documentos texto**
- *Dado semi-estruturado*
 - **Possui alguma estrutura (mas não completa)**
 - **e.g. um conjunto de mensagens possui uma estrutura simples que distingue quem enviou, quem recebeu (destinatário), o assunto, e o corpo da mensagem, mas a mensagem em si não é estruturada.**

BIG DATA

■ *Big data*

- *Dados não estruturados, dados semiestruturados, dados com pouca estrutura e dados ligeiramente estruturados são todos vários termos que descrevem dados com pouco ou nenhum metadado formal*
- *A falta de metadados formais em conjuntos de big data é causada pelo fato de que, ao contrário de bancos de dados operacionais e data warehouses, os repositórios de big data não são criados por meio do processo de modelagem formal de banco de dados*
- *Consequentemente, o big data não se encaixa facilmente em tabelas com linhas e colunas*

V's de BIG DATA

- *Na literatura, big data foi caracterizado com um número variável de V's*
 - *Três, quatro, cinco, seis ou mesmo sete V's: **Volume, Variety, Velocity, Veracity, Variability, Value, and Visualization***
 - *Embora **expressivo**, descrever big data com Vs simples também pode ser um pouco **confuso e enganoso***
 - *Esses V's declarados por conta própria, sem contexto ou exemplo, podem ser aplicados a bancos de dados operacionais e data warehouses também e, portanto, **não são completa e exclusivamente descritivos de big data***

V's de BIG DATA

- *Na literatura, big data foi caracterizado com um número variável de V's*
 - *Volume*
 - **Grande volumetria de dados**
 - *Variety*
 - **Abundância de diferentes tipos de fontes de dados**
 - *Velocity*
 - **Alta velocidade de entrada de dados**
 - *Veracity*
 - **Problemas de qualidade dos dados**

V's de BIG DATA


- *Na literatura, big data foi caracterizado com um número variável de V's*
 - *Variability*
 - **Possibilidade de interpretar os dados de diferentes maneiras**
 - *Value*
 - **Utilidade e capacidade de base para ação dos dados**
 - *Visualization*
 - **Necessidade de visualização elaborada dos dados**

Exemplo de visualização

Exemplo de visualização de um agrupamento (*cluster*) de dados socioeconômicos sob os municípios de Niterói e São Gonçalo.

Foram considerados indicadores de abastecimento de água, anos de estudo, coleta de lixo e renda.

O grupo em destaque na figura possui os melhores valores para os indicadores escolhidos.



V's de BIG DATA

■ *V's de Big Data*

- *Existem exemplos de V que são aplicáveis a bancos de dados operacionais, data warehouses e big data*
- *A fim de evitar imprecisão na descrição de big data com Vs simples, uma definição mais precisa de big data usando tais Vs é necessária*

DEFINIÇÃO DE BIG DATA


- *Big data refere-se aos **grandes volumes** de conjuntos de dados diversificados e de **crescimento rápido** que, quando comparados com bancos de dados operacionais e data warehouses:*
 - *são consideravelmente **menos estruturados**, com pouco ou nenhum **metadado***
 - *em geral, exibem **maior Volume, Velocidade e Variedade***
 - *têm **maior probabilidade de ter problemas de qualidade de dados (Veracidade)***
 - *têm uma **maior possibilidade de diferentes interpretações (Variabilidade)***
 - *precisa de uma **abordagem mais exploratória e experimental para gerar valor**, se houver*
 - *têm a mesma probabilidade (se não mais) de **se beneficiar de uma visualização elaborada e inovadora***

Ex.:
**Seguradora
de veículos**

EXAMPLE : Three Types of Data Sets in a Corporation

Insurance Company Operational Database

(ER Diagram and Relational Schema)



EXAMPLE : Three Types of Data Sets in a Corporation

Insurance Company Operational Database

(Sample Data)

CLAIM

<u>ClaimID</u>	<u>IncTypeID</u>	<u>CustID</u>	<u>CarPolicyID</u>	<u>VIN</u>	<u>ClaimDate</u>	<u>ClaimAmount</u>
C-111	IT1	111	CP11	1FM1111	1-Jan-2020	\$400
C-222	IT2	333	CP12	JHM2222	2-Jan-2020	\$900

INCLUDES

<u>CarPolicyID</u>	<u>CustID</u>
CP11	111
CP12	222
CP12	333

CUSTOMER

<u>CustID</u>	<u>CustName</u>	<u>CustYrOfBirth</u>	<u>CustGender</u>	<u>CustZip</u>
111	Tina	1982	Female	60137
222	Tony	1980	Male	60611
333	Pam	1981	Female	35401

CARPOLICY

<u>CarPolicyID</u>	<u>CarPolicyType</u>	<u>VIN</u>
CP11	Collision	1FM1111
CP12	Full coverage	JHM2222

INCIDENTTYPE

<u>IncType</u>	<u>Category</u>	<u>Subcategory</u>
IT1	Multi-car collision	Fender bender
IT2	Single-car collision	Front pole hit


CAR

<u>VIN</u>	<u>Make</u>	<u>Model</u>	<u>Year</u>
1FM1111	Ford	Escape	2018
JHM2222	Honda	Civic	2019

EXAMPLE : Three Types of Data Sets in a Corporation

Insurance Company Data Warehouse

(Star Schema)



EXAMPLE : Three Types of Data Sets in a Corporation

Insurance Company Data Warehouse

(Sample Data)

CALENDAR Dimension

<u>CalendarKey</u>	FullDate	DayOfWeek	Day	Month	Year
1	1/1/2020	Wednesday	1	January	2020
2	1/2/2020	Thursday	2	January	2020

CARPOLICY Dimension

<u>CarPolicyKey</u>	CarPolicyID	CarPolicyType	VIN	Make	Model	Year	BlueBook Value
1	CP11	Collision	1FM1111	Ford	Escape	2018	\$16,000
2	CP12	Full coverage	JHM2222	Honda	Civic	2019	\$12,000

CUSTOMER Dimension

<u>CustKey</u>	CustID	CustName	CustYearOfBirth	CustGender	CustZip
1	111	Tina	1982	Female	60137
2	222	Tony	1980	Male	60611
3	333	Pam	1981	Female	35401

INCIDENTTYPE Dimension

<u>IncTypeKey</u>	IncTypeID	IncTypeCategory	IncTypeSubcategory
1	IT1	Multi-car collision	Fender bender
2	IT2	Single-car collision	Front pole hit

CLAIMS Fact table

<u>CalendarKey</u>	CarPolicyKey	IncTypeKey	CustKey	<u>ClaimID</u>	ClaimAmount
1	1	1	1	C-111	\$400
2	2	2	3	C-222	\$900

EXAMPLE : Three Types of Data Sets in a Corporation

Insurance Company Big Data Set



(Sample Data generated by a Telemetry Device)

```
. . .  
1.1.2020; 10:00:00  
[(41.879632,-89.064769),0],[ (41.879632,-89.064769),0],[ (41.879632,-89.064769),0],  
[(41.898933, -89.061731),3],[ (41.900747,-89.064872),6], . . .  
. . .  
1.1.2020; 13:25:00  
[(41.898239,-87.628423),0],[ (41.898239,-87.628423),0],[ (41.897311,-87.627119),5],  
[(41.897105,-87.626878),12],[ (41.896594,-87.626792),18], . . .  
. . .  
1.1.2020; 18:33:05  
[(41.791636,-87.582976),0],[ (41.792100,-87.581989),7],[ (41.794307,-87.583534),16],  
[(41.793188,-87.580057),27],[ (41.794083,-87.579628),39], . . .  
. . .
```

EXAMPLE : Three Types of Data Sets in a Corporation

Insurance Company Big Data Set


(Sample Data generated by a Telemetry Device)




MAPREDUCE AND HADOOP

- *Banco de dados padrão e tecnologias de armazenamento de dados **não podem** fazer adequadamente*
 - *Capturar a falta de estruturação de grandes conjuntos de dados*
 - *Processar e realizar consultas complexas em grandes conjuntos de dados e alcançar um desempenho satisfatório*
- *MapReduce*
 - *Uma abordagem para lidar com Big Data*
 - **Map – mapeia cada registro em um par de chave-valor**
 - **Reduce - reúne todos os registros com a mesma chave e gera um único registro de saída para cada chave**
 - *Hadoop (High Availability Distributed Object Oriented Platform)*
 - **Open-source MapReduce implementation**

EXAMPLE : MapReduce Processing *Insurance Company Big Data Set (Telemetry Data)*



MAPREDUCE



Parte do hadoop responsável pelo processamento

- Map - Método de filtro e de ordenação dos dados
- Reduce - Método de sumarização do que foi mapeado


Talend(www)

V's de BIG DATA

■ *Exemplo – Examinando os V's de Big Data*

- **Volume** - *considere o volume de dados de telemetria*
- **Variety** - *considere a variedade de dispositivos capazes de gerar dados*
- **Velocity** - *considere a velocidade dos dados de telemetria*
- **Veracity** - *considere os possíveis problemas de qualidade de dados em dados de telemetria*
- **Variability** – *considere as possibilidades de interpretar os dados de telemetria de maneiras diferentes*
- **Visualization** – *considere as possibilidades de visualizar os dados de telemetria sob diferentes camadas (geoespacial)*
- **Value** – *considere o valor fornecido pelos dados de telemetria*

EXAMPLE : *Big Data as a Source for a Data Warehouse (Star Schema)*



EXAMPLE : Big Data as a Source for a Data Warehouse (Sample Data)

CALENDAR Dimension

<u>CalendarKey</u>	FullDate	DayOfWeek	Day	Month	Year
1	1/1/2020	Wednesday	1	January	2020
2	1/2/2020	Thursday	2	January	2020

CARPOLICY Dimension

<u>CarPolicyKey</u>	CarPolicyID	CarPolicyType	VIN	Make	Model	Year	BlueBook Value
1	CP11	Collision	1FM1111	Ford	Escape	2018	\$16,000
2	CP12	Full coverage	JHM2222	Honda	Civic	2019	\$12,000

CUSTOMER Dimension

<u>CustKey</u>	CustID	CustName	CustYearOf Birth	CustGender	CustZip	MSpeed Seg	MDistance Seg	MSkill Seg	MCaution Seg
1	111	Tina	1982	Female	60137	9	9	8	8
2	222	Tony	1980	Male	60611	8	7	6	7
3	333	Pam	1981	Female	35401	7	4	6	7


INCIDENTTYPE Dimension

<u>IncTypeKey</u>	IncTypeID	IncTypeCategory	IncTypeSubcategory
1	IT1	Multi-car collision	Fender bender
2	IT2	Single-car collision	Front pole hit

CLAIMS Fact table

<u>CalendarKey</u>	<u>CarPolicyKey</u>	<u>IncTypeKey</u>	<u>CustKey</u>	<u>ClaimID</u>	ClaimAmount
1	1	1	1	C-111	\$400
2	2	2	3	C-222	\$900

EXPANDED EXAMPLE : *Big Data as a Source for a Data Warehouse (Star Schema)*



EXPANDED EXAMPLE : *Big Data as a Source for a Data Warehouse (Sample Data)*

CALENDAR Dimension

<u>CalendarKey</u>	FullDate	DayOfWeek	Day	Month	Year
1	1/1/2020	Wednesday	1	January	2020
2	1/2/2020	Thursday	2	January	2020

CARPOLICY Dimension

<u>CarPolicyKey</u>	CarPolicyID	CarPolicyType	VIN	Make	Model	Year	BlueBook Value
1	CP11	Collision	1FM1111	Ford	Escape	2018	\$16,000
2	CP12	Full coverage	JHM2222	Honda	Civic	2019	\$12,000

CUSTOMER Dimension

<u>Cust Key</u>	CustID	Cust Name	CustYear OfBirth	Cust Gender	CustZip	MSpeed Seg	MSpeed SegCh	MDist Seg	MDist SegCh	MSkill Seg	MSkill SegCh	MCaut Seg	MCaut SegCh
1	111	Tina	1982	Female	60137	9	+1	9	0	8	-2	8	-3
2	222	Tony	1980	Male	60611	8	0	7	0	6	+1	7	0
3	333	Pam	1981	Female	35401	7	0	4	0	6	0	7	+1

INCIDENTTYPE Dimension

<u>IncTypeKey</u>	IncTypeID	IncTypeCategory	IncTypeSubcategory
1	IT1	Multi-car collision	Fender bender
2	IT2	Single-car collision	Front pole hit

CLAIMS Fact table

<u>CalendarKey</u>	<u>CarPolicyKey</u>	<u>IncTypeKey</u>	<u>CustKey</u>	<u>ClaimID</u>	ClaimAmount
1	1	1	1	C-111	\$400
2	2	2	3	C-222	\$900

Descoberta de perfis de motoristas



Lab EMR

<https://classroom.github.com/a/LYmoZtNR>

Rodando contagem de palavras no hadoop

Formatar

hdfs namenode -format

Iniciar

start-dfs.sh

Ver status

jps

hdfs dfsadmin -report

Carregar arquivos

hdfs dfs -mkdir livros

cd /home/hadoop

wget -O hamlet.txt <http://www.gutenberg.org/files/27761/27761-0.txt>

wget -O os_demonios.txt <http://www.gutenberg.org/files/8117/8117-0.txt>

wget -O don_quixote.txt <http://www.gutenberg.org/files/996/996-0.txt>

wget <https://www.textos.com.br/texto/romance/geral/dom-casmurro>

hdfs dfs -put hamlet.txt os_demonios.txt don_quixote.txt livros

hdfs dfs -ls livros

Iniciar yarn

start-yarn.sh

yarn node -list

Rodando contagem de palavras no hadoop, em java e em python

Rodando o map-reduce

```
yarn jar ~/hadoop/share/hadoop/mapreduce/hadoop-mapreduce-examples-3.3.1.jar wordcount "books/*" output
```

Rodando o map-reduce em Python (www)

```
mapred streaming -input livros -output mroutput -file mapper.py -file reducer.py -mapper mapper.py -reducer reducer.py
```


mapper.py

```
#!/usr/bin/env python

import sys

# input comes from STDIN (standard input)
for line in sys.stdin:
    # remove leading and trailing whitespace
    line = line.strip()
    # split the line into words
    words = line.split()
    # increase counters
    for word in words:
        # write the results to STDOUT (standard
output);
        # what we output here will be the input for
the
        # Reduce step, i.e. the input for reducer.py
        #
        # tab-delimited; the trivial word count is 1
        print '%s\t%s' % (word, 1)
```

reducer.py

```
#!/usr/bin/env python
from operator import itemgetter
import sys

current_word = None
current_count = 0

for line in sys.stdin:
    line = line.strip()

    # parse the input we got from mapper.py
    word, count = line.split('\t', 1)
    count = int(count)

    # this IF-switch only works because Hadoop sorts
    map output
    # by key (here: word) before it is passed to the
    reducer
    if current_word == word:
        current_count += count
    else:
        if current_word:
            print '%s\t%s' % (current_word,
current_count)
            current_count = count
            current_word = word

# do not forget to output the last word if needed!
print '%s\t%s' % (current_word, current_count)
```

Teste no shell

```
[hadoop@ip-172-31-33-196 ~]$ echo "um doi tres tres
quatro"
um doi tres tres quatro
[hadoop@ip-172-31-33-196 ~]$ echo "um doi tres tres
quatro" | ./mapper.py
um      1
doi     1
tres    1
tres    1
quatro  1
[hadoop@ip-172-31-33-196 ~]$ echo "um doi tres tres
quatro" | ./mapper.py | sort -n
doi     1
quatro  1
tres    1
tres    1
um      1
[hadoop@ip-172-31-33-196 ~]$ echo "um doi tres tres
quatro" | ./mapper.py | sort -n | ./reducer.py
doi     1
quatro  1
tres    2
um      1
```

Teste no hadoop

Dom Casmurro

```
hadoop jar /usr/lib/hadoop-mapreduce/hadoop-streaming-2.10.1-amzn-1.1.jar -file  
/home/hadoop/mapper.py -mapper /home/hadoop/mapper.py -file /home/hadoop/reducer.py -reducer  
/home/hadoop/reducer.py -input /user/hadoop/livros/* -output /user/hadoop/livros-output
```

```
hdfs dfs -ls /user/hadoop/livros-output
```

```
Found 2 items
```

```
-rw-r--r--    1 hadoop hdfsadmingroup          0 2021-10-11 20:40 /user/hadoop/livros-  
output/_SUCCESS
```

```
-rw-r--r--    1 hadoop hdfsadmingroup    296478 2021-10-11 20:40 /user/hadoop/livros-  
output/part-00000
```

```
hdfs dfs -cat /user/hadoop/livros-output/part-00000 |more
```

```
.....
```



```
hdfs dfs -cat /user/hadoop/livros-output/part-00000 | sort -n -k 2
```

....

ou	263
à	266
mais	296
minha	297
no	304
na	307
como	323
ao	324
por	343
uma	386
eu	412
em	420
era	444
mas	470
me	488
as	492
se	521
com	523
para	536
do	596
os	613
da	616
é	620
um	705
não	1158
o	1512
de	1944
e	2008
a	2260
que	2543

Teste no hadoop
*ordenado pelas palavras que
mais apareceram*

DL vs DW

CORPORATE USE OF BIG DATA

■ *Big data methods:*

- *Aumentar a capacidade de analisar os dados que a organização possui ou aos quais tem acesso*
 - **É um erro comum tratar o big data como um problema de dados completamente separado e distinto**
 - **A abordagem integrada, aonde uma iniciativa de big data anda de mãos dadas com outros projetos de dados, é mais benéfica**
- *Não substitua as abordagens tradicionais de banco de dados, desenvolvidas para gerenciar e utilizar modelos relacionais e dimensionais*
 - **As abordagens tradicionais permitem que as organizações analisem e obtenham uma visão dos tipos de dados que não são adequados para SGBDs e DWs**

DATA LAKE


■ *Data Warehouse*

- *Armazena dados em uma estrutura de destino predefinida com metadados detalhados (por exemplo, esquemas em estrela)*
 - **Os usuários recuperam e analisam dados**


■ *Data Lake*

- *Um grande pool de dados em que o esquema e os requisitos de dados não são definidos até que os dados sejam consultados*
- *O data lake armazena uma grande quantidade de dados brutos em seu formato nativo até que seja necessário*
 - **Essa abordagem costuma ser chamada de esquema na leitura ou esquema sob demanda**
 - **Os usuários devem preparar e transformar os dados antes de analisá-los**

DATA LAKE vs DATA WAREHOUSE



DATA LAKE vs DATA WAREHOUSE



DATA LAKE

- *Um conceito adequado para o armazenamento de big data*

DATA LAKE

- *O Data Lake é uma alternativa adequada para um data warehouse?*
 - *OK, se as empresas desejam, de forma consciente e deliberada, uma abordagem mais barata e flexível e, ao mesmo tempo, uma abordagem menos organizada e menos poderosa para a análise de alguns de seus dados estruturados*
 - *Não OK, se as empresas tiverem uma visão superficial dos data lakes como uma alternativa equivalente (e ainda de alguma forma magicamente mais barata) aos data warehouses*
 - **Nesses casos, as empresas acabam com uma massa pesada de dados díspares (ou seja, selva de dados ou pântano de dados)**
 - **Isso exige que os analistas dediquem a maior parte de seus esforços para localizar e preparar os dados necessários, sacrificando a quantidade de tempo que podem dedicar à análise real**

DATA LAKE

- *Data Warehouse vs Data Lake*
 - *Analogia: agricultura vs caça / coleta*

DATA LAKE

- *Espectro de soluções para grandes repositórios de dados analíticos*

DATA
LAKE

DATA
WAREHOUSE

Spectrum of Solutions for Large Analytical Data Repositories

- native format of data
- no transformation
- no integration



Less transformation and
integration



More transformation and
integration

- complete ETL
infrastructure in place
- data transformed and
integrated for analysis

DATA LAKE

- *Espectro de soluções para grandes repositórios de dados analíticos*
 - *Um data warehouse totalmente desenvolvido e um data lake estão nas extremidades opostas de um amplo espectro de soluções para grandes repositórios de dados analíticos*
 - *Um exemplo dentro desse espectro*
 - **Transformações rápidas e simples de dados de origem para mesclar dados em um formulário padronizado para uso ad-hoc, sem necessariamente ter esquemas em estrela elaborados e chaves substitutas**
 - *Na prática, dentro deste espectro, é comum ouvir os termos "data warehouse" ou "data lake" usados livremente (por pessoas que não aderem às definições adequadas desses termos) para descrever soluções que não necessariamente se referem aos fins do espectro*

DATA LAKE

- *Espectro de soluções para grandes repositórios de dados analíticos*
 - *Permite soluções que combinam o uso de data warehouses e data lakes*
 - *Exemplo:*
 - **Os dados analíticos mais comumente usados são mantidos em um data warehouse**
 - **Conforme necessário, esses dados podem ser combinados com os dados de um data lake para soluções analíticas mais complexas e exploratórias**