

MODELAGEM INFORMACIONAL

Organizações data-driven



Júlio César Chaves

Abril, 2024

julio.cesar.chaves@prof.fgv.edu.br

REFERÊNCIAS

- *Material do curso Data Engineering da AWS academy*



"Through 2026, organizations will accelerate their investments in data and analytics services by 45 percent to become more data driven and digital."

Gartner

Forecast Analysis: Data and Analytics Services, Worldwide,

Twiggy Lo, March 2022

Como você decide ...

Qual restaurante perto de mim serve a melhor comida tailandesa?

Onde posso encontrar uma bicicleta infantil usada?

Quais jogadores devo escolher para o meu time de futebol no game?

Que tipo de trabalho devo seguir?

Quanto devo pagar por esta casa?

Como as organizações decidem...

Quais dessas transações de clientes devem ser sinalizadas como fraude?

Qual design de página web leva ao maior número de vendas concluídas?

Quais pacientes são mais propensos a ter uma recaída?

Qual tipo de atividade online representa um problema de segurança?

Qual é a época ideal para colher a safra deste ano?

Reflita sobre um exemplo de sua organização...

Dando base para decisões com ciência de dados

Data Analytics

Análise sistemática de grandes conjuntos de dados (big data) para encontrar padrões e tendências para produzir insights acionáveis.

Usa lógica de programação para responder a perguntas a partir de dados.

É bom para dados estruturados com um número limitado de variáveis.

AI/ML

É um conjunto de modelos matemáticos que são usados para fazer previsões a partir de dados em uma escala que é difícil ou impossível para humanos.

Usa exemplos de grandes quantidades de dados para aprender sobre os dados e responder a perguntas.

É bom para dados não estruturados e onde as variáveis são complexas.

Exemplo: identificar fotos com cães

Data analytics approach

Com base num conjunto de características definidas, quais destas imagens são cães?

Imagem mapear todas as características.



AI/ML approach

Quais destas imagens têm as mesmas características das imagens que vi e que foram rotuladas como cães?



Exemplo de negócio: CRM

Data analytics approach

Uma empresa de varejo analisa a receita total por cliente e segmenta os clientes em categorias com base nos gastos.


A segmentação pode ser usada para oferecer um nível mais alto de atendimento aos clientes que gastam mais.

AI/ML approach


Uma empresa de varejo usa IA/ML para analisar a rotatividade de clientes (por que e com que frequência os clientes entram e saem).

A IA/ML pode descobrir fatores que influenciam a rotatividade para que a empresa possa fazer mudanças para reter melhor os clientes.

Insights mais valiosos são mais difíceis de obter




Mais dados e menos barreiras = mais decisões baseadas em dados




MAIS CIÊNCIA DE DADOS NO DIA A DIA

- *Você está comprando sapatos online e começa a ver muitos anúncios relacionados a calçados.*
- *Você assiste a um filme ou ouve uma música em uma plataforma de streaming e começa a receber recomendações de filmes ou músicas de que também pode gostar.*
- *Você pede pizza online e fica atualizado sobre cada etapa do processo de preparação e entrega.*
- *Você usa seu cartão de crédito fora de sua área geográfica habitual e recebe alertas adicionais de fraude de seu banco.*
- *O aplicativo de navegação do telefone alerta você sobre um engarrafamento.*

Mais dados não são necessariamente iguais a mais valor



Os dados tornam-se menos valiosos para a tomada de decisões ao longo do tempo



Os trade-offs das decisões baseadas em dados



Custo

Quanto você deve investir para ir mais rápido ou prever com mais precisão?

Quanta melhoria incremental justifica o custo adicional?

Velocidade

Com que rapidez você precisa de uma resposta?

Você pode sacrificar a precisão pela velocidade?

Exatidão

Qual o nível de precisão da previsão?

Esperar por uma resposta melhor compensa responder mais rapidamente?

Key takeaways: Data-driven decisions



As organizações orientadas por dados usam a ciência de dados para tomar decisões informadas.

A análise de dados depende de lógica de programação e ferramentas para chegar a previsões a partir dos dados. Essa abordagem é boa para dados estruturados com um número limitado de variáveis.

AI/ML pode aprender a fazer previsões a partir de exemplos de dados. Essa abordagem é boa para dados não estruturados e onde as variáveis são complexas.

Um grande aumento de dados disponíveis, juntamente com uma diminuição no custo da tecnologia relevante, aumenta a oportunidade para decisões baseadas em dados.


O pipeline de dados – infraestrutura para decisões baseadas em dados

Organizações orientadas por dados

Um pipeline de dados em seus termos mais simples



Coletar dados



Armazenar e
processar dados



Criar algo útil com
os dados

Trabalhe de trás para frente ao projetar sua infraestrutura




2. Que dados você precisa para apoiar isso?

1. Que decisão você está tentando tomar?




Pese as compensações de custo, velocidade e precisão.


Camadas da infraestrutura de dados




Ações tomadas com dados no pipeline



Processamento iterativo através do pipeline



Exemplo: um pipeline simples



Key takeaways: The data pipeline – infrastructure for data-driven decisions



Um pipeline de dados fornece a infraestrutura para a tomada de decisões baseada em dados.

Ao projetar um pipeline, comece com o problema de negócios a ser resolvido e trabalhe retroativamente até os dados.

O pipeline inclui camadas para ingerir, armazenar, processar, analisar e visualizar dados que passam por ele.

A organização de dados refere-se a como os dados são tratados à medida que passam pelo pipeline. As tarefas incluem descoberta, limpeza, normalização, transformação e aumento.

Os dados são processados iterativamente para avaliar e melhorar os resultados.

O papel do engenheiro de dados em organizações orientadas a dados


Organizações orientadas por dados

Perguntas comuns sobre pipeline de dados



Data
engineer

- A organização possui os dados que atendem à necessidade? Onde os dados são armazenados e em que formato?
- Precisarei combinar dados de múltiplas fontes?
- Qual é o tipo e a qualidade dos dados? Qual será a fonte única que leva a verdade?
- Quais são os requisitos de segurança para esses dados? Quem precisa de acesso a ele e em que estado?
- Que tipos de mecanismos são necessários para transferir os dados de suas localizações para o pipeline?
- Quantos dados existem e com que frequência são atualizados ou processados?
- Quão importante é a velocidade quando os dados são solicitados?



- O que os dados podem me dizer?
- Como avaliarei os resultados?
- Que tipo de visualização eu preciso?
- Com quais formatos e ferramentas os analistas estão familiarizados?
- Preciso de uma estrutura de big data?
- Que tipo de modelos de IA/ML são adequados?
- Qual é a maneira mais simples de implementar IA/ML?



Data
scientist

Key takeaways: The role of the data engineer in data-driven organizations



Tanto as funções de cientista de dados quanto as funções de engenharia de dados trabalham com o pipeline de dados, e as tarefas podem ser executadas por alguém em qualquer uma das funções.


A engenharia de dados concentra-se principalmente na infraestrutura pela qual os dados passam enquanto o cientista de dados trabalha com os dados no pipeline.

Para construir o pipeline certo, você precisa fazer perguntas sobre os resultados desejados e os dados e, em seguida, repetir suas respostas à medida que aprende mais.


Modern data strategies

Data-Driven Organizations

Estratégia em três frentes para criar infraestrutura de dados



Modernizar



Unificar



Inovar


Modernizar

Aumente a agilidade e reduza a infraestrutura monolítica (capex) ex.: tudo em um servidor.

Migrar de serviços locais para serviços baseados em nuvem. (nem sempre)

Migre para ferramentas e armazenamentos de dados criados especificamente para esse fim. (tecnologias específicas para a finalidade)

Construa pipelines fracamente acoplados. (fracamente acoplados)



Unificar

Crie uma única fonte de verdade(fonte única da verdade)


Quebre silos de dados.

Democratizar o acesso.

Equipe os usuários com ferramentas para visualizar seus próprios insights.

Use um data lake e execute consultas diretamente nos dados.

Ofereça suporte à governança e à movimentação simplificadas entre o data lake e os armazenamentos criados especificamente para esse fim.



Inovar

Use IA e ML para descobrir novos insights mais rapidamente

Passe da tomada de decisão reativa para a proativa.

Incorpore IA/ML na tomada de decisões e aproveite novos insights em grandes quantidades de dados não estruturados.

Aproveite os serviços de nuvem com recursos de IA/ML que democratizam quem pode usar o ML.



Reflexão: os elementos de uma atividade de dados

Quais insights podem ser extraídos dos dados?

Quão precisos e confiáveis são os dados?

Quais tipos e formatos? Quantas fontes diferentes de dados?

Qual a frequência de novos dados sendo gerados e ingeridos?

Qual o tamanho do conjunto de dados? Quantos novos dados são gerados?

Valor

Que detalhes você sabe sobre os dados (por exemplo, campos e tipos de campo)?

Que tipo de análise e quanto processamento pode ser necessário para obter insights?

Veracidade

Que tipo de leis de privacidade podem afetar a coleta e retenção de dados em diferentes geografias e setores?

Que tipo de limpeza e transformações podem ser necessárias para usar esses dados?

Variedade

Com que rapidez os dados ficariam obsoletos?

Como essa fonte de dados será combinada com outras fontes de dados?

Velocidade

O volume de dados que é ingerido no pipeline estaria em nível constante ou seria intermitente? Os padrões são previsíveis?

Os dados precisam ser processados e analisados quase em tempo real para serem valiosos?

Volume

Qual seria o volume geral e a velocidade dos dados recebidos? Como os dados podem ser transferidos para o seu sistema (por exemplo, FTP ou um dispositivo conectado)?



"Ser uma organização orientada por dados significa tratar culturalmente os dados como um ativo estratégico e, em seguida, construir capacidades para colocar esse ativo em uso – não apenas para grandes decisões, mas também para ações diárias na linha de frente."

Ishit Vachhrajani, AWS Enterprise Strategist

Key takeaways: Modern data strategies



As organizações que desejam tornar-se orientadas por dados devem modernizar, unificar e inovar com as suas infraestruturas de dados.

Modernizar significa migrar para infraestruturas baseadas em nuvem (inclusive nuvem privada) e serviços desenvolvidos especificamente para reduzir o esforço administrativo e operacional.

Unificar significa criar uma única fonte de verdade para os dados e disponibilizá-los em toda a organização.

Inovar significa procurar novas maneiras de encontrar valor nos dados – especificamente, aplicar IA e ML para encontrar novos insights.