

MODELAGEM INFORMACIONAL

Dados não estruturados



Streaming de dados

Abril, 2023

julio.cesar.chaves@prof.fgv.edu.br

Júlio César Chaves

regex

Regex - origem

Novamente álgebra

1943

McCulloch e Pitts desenvolveram modelos que descrevem como funciona o sistema nervoso humano.

<https://www.cs.cmu.edu/~./epxing/Class/10715/reading/McCulloch.and.Pitts.pdf>

1956

Stephen Kleene descreveu os modelos existentes com uma notação de álgebra que ele chamou de conjuntos regulares/expressão regular.

https://www.rand.org/content/dam/rand/pubs/research_memoranda/2008/RM704.pdf

Novamente um matemático

1968

*Ken Thompson, um **matemático** e um dos principais desenvolvedores do UNIX, implementou expressões regulares dentro do editor de texto chamado *ed*. Esse é o ponto de entrada do *regX* no mundo da computação.*

<https://dl.acm.org/doi/10.1145/363347.363387>

Expressão regular

Introdução

Introduction to Regular Expressions | by David Farrugia | Towards Data Science

(David Farrugia)

A expressão regular é...

Basicamente uma sequência de caracteres que define uma forma que corresponde a um padrão de pesquisa desejado.

Regex não é ...

Uma linguagem de programação.

A aplicação é vasta

A regex geralmente é usada para extrair metadados de dados não-estruturados.

No exemplo acima, se busca separar os nomes de seriados e filmes.

A regex pode ser usada dentro de um SQL, por exemplo.

```
REGULAR EXPRESSION

# get the title of this movie or series
(?P<title>.*?)

# match separator to later replace into correct title
(?P<separator>[\.\-\_])


# note this must be lazy for the engine to work ltr not rtl
(?:[-\w!]+\2)*?

# start of movie vs serie check
(?:

TEST STRING

the.black.adder.3x01.dish.and.dishonesty.dvdrip.xvid-dvdiso.avi
the.black.adder.3x02.ink.and.incapability.dvdrip.xvid-dvdiso.avi
the.black.adder.3x03.nob.and.nobility.dvdrip.xvid-dvdiso.avi
the.black.adder.3x04.sense.and.senility.dvdrip.xvid-dvdiso.avi
the.black.adder.3x05.amy.and.amiability.dvdrip.xvid-dvdiso.avi
the.black.adder.3x06.duel.and.duality.dvdrip.xvid-dvdiso.avi
Game.of.Thrones.S04E08.720p.HDTV.x264-KILLERS
Futurama.S06.720p.BluRay.X264-REWARD-SINNERS
```

Regex - como fazer



/^\\s*#?([A-F0-9]{6}|[A-F0-9]{3})\\s*\$/i


REGULAR EXPRESSION

:/^\\s*#?([A-F0-9]{6}|[A-F0-9]{3})\\s*\$/i

TEST STRING

.....#b63.....

Flags: Ignore Case



Imaginando a captura de valores de cores em hexadecimal (base 16).

Regex - como fazer

Quais são os principais comandos?

Use o testador on-line:

[regex101: build, test, and debug regex](#)

/ — delimiter (start and end of regex)

? — match 0 or 1 time

* - match 0 or more times

+ — match 1 or more times

[] — range of acceptable values

{ } — exactly n characters

| — create different branches

() — grouping

i — case insensitive

^ — anchor to the beginning of the string

\$ — anchor to the end of the string

Contador de palavras

Elaborar contador de palavras, tal qual map-reduce

Solved: How can I get a count of words in an event? - Splunk Community

splunk

Dados não estruturados

Texto

Game.of.Thrones.S04E08.720p.HD
TV.x264-
KILLERSFuturama.S06.720p.BluRay
.X264-REWARD-
SiNNERSThe.Grand.Budapest.Hotel
.2014.1080p.BluRay.x264-
BLOWAnother.Earth.2011.LIMITED.
720p.BluRay.X264-
AMIABLEGame.of.Thrones.S04E09.
720p.HDTV.x264-
KILLERSThe.Green.Mile.1999.720p.
BluRay.x264

Video AI: análise de conteúdo
de vídeo | API Cloud Video
Intelligence | Google Cloud

Vídeo



Revival de Futurama ganha
previsão de lançamento
(uol.com.br)

Speech-to-Text:
reconhecimento de fala
automático | Google Cloud

Audio




<https://www.spreaker.com/>

Sobre o splunk

Ver vídeo

Thank You for Downloading Splunk Enterprise | Splunk



Splunk - instalação no lab

Instalação do splunk Enterprise - trial 60 dias

Abrir no Chrome

http://127.0.0.1:8000/en-US/account/login?return_to=%2Fen-US%2F

User = admin

Senha = P@s5W0rdXPTO

Está no nosso lab:

RDPAZUCPR0003.acad.fgv.br:53287
(Remote Desktop)


191.235.80.65:53287

Criação de consultas

`source="local network monitor"`
`host="RDPAZUCPR0003"`
`sourcetype="WinNetMon"`

`source="WinEventLog:*"`
`host="RDPAZUCPR0003"`

Carregar o próprio CSV.



Lab splunk

Analisar logs do windows



Add Data

Add or forward data to Splunk Enterprise. Afterwards, you may [extract fields](#).



Monitor

files and ports on this Splunk platform instance

Files - HTTP - WMI - TCP/UDP - Scripts
Modular inputs for external data sources

Local Event Logs

Collect event logs from this machine.

Review

Input Type Windows Event Logs

Event Logs Security

App Context search

Host RDPZUCPR0003

Index default



Local event logs in

Configure your inputs by going

Start Searching

Search


New Search

source="WinEventLog:*" host="RDPAZUCPR0003"

✓ 121,548 events (before 5/8/23 10:29:41.000 AM) No Event Sampling ▾

Events (121,548) Patterns Statistics Visualization

Format Timeline ▾ — Zoom Out + Zoom to Selection × Deselect



List ▾ ↗ Format 20 Per Page ▾

< Hide Fields

≡ All Fields

SELECTED FIELDS

a host 1

a source 1

a sourcetype 1

INTERESTING FIELDS

a Account_Domain 11

a Account_Name 100+

a Algorithm_Name 3

a ComputerName 1

date_hour 24

date_mday 20

date_minute 60

a date_month 2

i

Time

Event

>

5/8/23
10:29:39.000 AM

05/08/2023 10:29:39 AM
LogName=Security
EventCode=4625
EventType=0
ComputerName=RDPAZUCPR0003.acad.fgv.br
[Show all 61 lines](#)
host = RDPAZUCPR0003 | source = WinEvent

>

5/8/23
10:29:36.000 AM

05/08/2023 10:29:36 AM
LogName=Security
EventCode=4625
EventType=0
ComputerName=RDPAZUCPR0003.acad.fgv.br
[Show all 61 lines](#)
host = RDPAZUCPR0003 | source = WinEvent

Analisar um CSV



Add Data

Add or forward data to Splunk Enterprise. Afterwards, you may [extract fields](#).



Upload

files from my computer

Local log files
Local structured files (e.g. CSV)
[Tutorial for adding data](#)

Use log de saída "CSV" de sua view do Fato Vendas.

Review

Input Type	Uploaded File
File Name	fato_vendas_zagibr.csv
Source Type	csv
Host	RDPAZUCPR0003
Index	Default

New Search

```
source="fato_vendas_zagibr.csv" host="RDPAZUCPR0003" sourcetype="csv" NomeProduto="*30M1*"
```

2 events before 5/8/23 10:37:43 AM No Event Sampling

Busca por e-mails válidos.

`[a-zA-Z0-9_+-.]+@[a-zA-Z0-9-]+.[a-zA-Z0-9-]+`

```
REGULAR EXPRESSION
: / [a-zA-Z0-9_+-.]+@[a-zA-Z0-9-]+.[a-zA-Z0-9-]+

TEST STRING
asm0dey@asm0dey.ru
pavel.finkelshtein@gmail.com
som@ibrae.ac.ru
my@localhost
julio.chaves@
```