

Lista 1 — Machine Learning @FGV

Diego Mesquita

FGV EMaP

Questão 1 Bias-variance tradeoff

Nas nota de aula, derivamos o "dilema viés-variância" calculando o MSE esperado entre a função alvo de aprendizado f e a predição do nosso modelo $h_{\mathcal{D}}$:

$$\mathbb{E}_{x, \mathcal{D}} \left[(h_{\mathcal{D}}(x) - f(x))^2 \right] = \mathbb{E}x[\underbrace{\text{Var}_{\mathcal{D}}[h_{\mathcal{D}}(x)]}_{\text{Variância}}] + \mathbb{E}x[\underbrace{(\mathbb{E}_{\mathcal{D}}[h_{\mathcal{D}}(x)] - f(x))^2}_{\text{Viés}}].$$

Com isso em mente, adapte nossa derivação para o caso em que as respostas de teste $f(x)$ são corrompidas por um ruído aditivo aleatório ϵ com média zero, i.e., observamos $f'(x) = f(x) + \epsilon$. Mais concretamente, trabalhe a seguinte esperança para derivar uma decomposição similar à da nota de aula:

$$\mathbb{E}_{x, \epsilon, \mathcal{D}} \left[(h_{\mathcal{D}}(x) - f'(x))^2 \right]$$

Compare a diferença entre a decomposição que você obteve e a da nota de aula.

Dica: sua decomposição deve se diferenciar da acima em apenas um termo aditivo, que envolve uma esperança sobre x e y .

Questão 2 Posteriori preditiva de GPs

Na nota de aula, derivamos a posteriori preditiva $p(y_{\star}|x_{\star}, x_1, y_1, \dots, x_N, y_N)$ modelos de GP para regressão com verossimilhança Gaussiana. Por simplicidade, deduzimos a priori preditiva $p(y_{\star}, y_1, \dots, y_N|x_{\star}, x_1, \dots, x_N)$ e as condicionamos nas saídas $y_1, \dots, y_N$ observadas no conjunto de treino. No entanto, também é possível obter o mesmo resultado calculando a posteriori $p(f_{\star}, f_1, \dots, f_N|x_{\star}, x_1, y_1, \dots, x_N, y_N)$ e, então, calculando o valor esperado de $p(y_{\star}|x_{\star}, f_{\star})$ sob essa posteriori. Deduza novamente a posteriori preditiva seguindo esse outro procedimento.

Questão 3 GPs para classificação

Quando trocamos a verossimilhança Gaussiana por uma Bernoulli (i.e., no caso de classificação binária), a posteriori para nosso GP não possui fórmula fechada. Mais especificamente, a verossimilhança para esse modelo é dada por $y|x \sim \text{Ber}(\sigma(f(x)))$ onde σ é a função sigmoide. Em resposta à falta de uma solução analítica, podemos aproximar a posteriori sobre f para qualquer conjunto de pontos de entrada usando as técnicas de inferência aproximada que vimos anteriormente. Discuta como usar a aproximação de Laplace nesse caso, incluindo as fórmulas para os termos da Hessiana. Além disso, discuta como usar o resultado desse procedimento para aproximar a posteriori preditiva.

Questão 4 Invariâncias e equivariâncias de GNNs

Suponha que dois grafos $G_1 = (\mathbf{X}^{(1)}, \mathbf{A}^{(1)})$ e $G_2 = (\mathbf{X}^{(2)}, \mathbf{A}^{(2)})$ são isomorfos. Prove que o multi-conjunto gerado por uma GNN seguindo o paradigma de message-passing para os embeddings dos nós de G_1 é igual ao gerado para os nós de G_2 . Aqui, $\mathbf{X}^{(1)}$ e $\mathbf{X}^{(2)}$ denotam matrizes contendo os embeddings de nó e $\mathbf{A}^{(1)}$ e $\mathbf{A}^{(2)}$ denotam as matrizes de adjacência dos grafos em questão.

Questão 5 Convolução como caso especial de camada totalmente conectada




Figure 1: Representação de uma camada convolucional como uma camada totalmente conectada esparsa. As conexões vermelhas e azuis indicam pesos compartilhados aplicados a diferentes posições do vetor de entrada.

Considere uma camada de rede convolucional com uma entrada unidimensional e um mapa de características unidimensional, como mostrado na Figura 1. Suponha que a entrada tenha dimensionalidade 5, e que os filtros tenham largura 3 e stride 1. Mostre que essa operação pode ser expressa como um caso especial de uma camada totalmente conectada, escrevendo a matriz de pesos na qual conexões ausentes são substituídas por zeros e onde parâmetros compartilhados são indicados por entradas replicadas. Ignore quaisquer parâmetros de viés.

Questão 6 Equivalência entre redes com ativações sigmoide e tangente hiperbólica

Considere uma rede neural com duas camadas, definida pela seguinte equação:

$$y_k(\mathbf{x}, \mathbf{w}) = \sigma \left(\sum_{j=1}^M w_{kj}^{(2)} \cdot h \left(\sum_{i=1}^D w_{ji}^{(1)} x_i + w_{j0}^{(1)} \right) + w_{k0}^{(2)} \right), \quad (1)$$

em que $\sigma(a) = (1 + \exp(-a))^{-1}$ é a função sigmoide logística e $h(\cdot)$ é também $\sigma(\cdot)$, ou seja, a ativação oculta também é sigmoide.

Mostre que existe uma rede equivalente que computa exatamente a mesma função, mas usando funções de ativação $\tanh(a)$ nas unidades ocultas, onde a função tangente hiperbólica é definida por:

$$\tanh(a) = \frac{e^a - e^{-a}}{e^a + e^{-a}}.$$

Dica: comece encontrando a relação matemática entre $\sigma(a)$ e $\tanh(a)$. Em seguida, mostre como os pesos e os vieses da rede original devem ser transformados para manter a mesma função $y_k(\mathbf{x}, \mathbf{w})$ quando as ativações ocultas passam a ser $\tanh(a)$ em vez de $\sigma(a)$.