

3. Métodos de vizinhos mais próximos

Um das hipóteses fundamentais em ML é que existe algum nível de suavidade no mapeamento entre o espaço de entrada $\mathcal{X}$ e o de saída $\mathcal{Y}$. Em outras palavras, se dois elementos $\mathbf{x}, \mathbf{x}' \in \mathcal{X}$ devem ter saídas $y, y' \in \mathcal{Y}$ similares. O método dos k vizinhos mais próximos (k nearest neighbors, k -NN), proposto por Cover e Hart (1967), aplica diretamente esse conceito.

Nesse capítulo, vamos estudar como k -NN pode ser usados para problemas de classificação e regressão. Discutiremos o impacto do k e também da escolha de distância (ou métrica) para o espaço $\mathcal{X}$, que é primordial para a aplicação do método. Finalmente, estudaremos o comportamento do método k -NN quando a dimensionalidade do espaço $\mathcal{X}$ é alta.

3.1 k -NN para classificação

Seja $\mathcal{D} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\} \in \mathcal{X} \times \mathcal{Y}$ o nosso conjunto de treinamento e $d : \mathcal{D} \times \mathcal{D} \rightarrow \mathbb{R}^+ \cup \{0\}$ uma função de distância. Suponha que queiramos classificar um vetor arbitrário $\mathbf{x} \in \mathcal{X}$. Para fazer tal com k -NN, precisamos primeiro definir uma vizinhança $\mathcal{V}_k(\mathbf{x})$ ao redor de $\mathbf{x}$ contendo k elementos. Informalmente, definimos $\mathcal{V}_k(\mathbf{x})$ como o conjunto dos k pares ordenados $(\mathbf{x}_i, y_i) \in \mathcal{D}$ com valores de entrada $\mathbf{x}_i$ mais próximos a $\mathbf{x}$. Mais precisamente, a vizinhança $\mathcal{V}_k(\mathbf{x}) \subseteq \mathcal{D}$ é o subconjunto de $\mathcal{D}$, com cardinalidade k , que satisfaz

$$\forall (\mathbf{x}'', y'') \in \mathcal{D} \setminus \mathcal{V}_k(\mathbf{x}) : d(\mathbf{x}, \mathbf{x}'') \geq \max_{(\mathbf{x}', y') \in \mathcal{V}_k(\mathbf{x})} d(\mathbf{x}, \mathbf{x}'). \quad (3.1)$$

Note que a condição na Equação 3.1 implica que qualquer ponto de treinamento fora da vizinhança $\mathcal{V}_k(\mathbf{x})$ está pelo menos tão distante de $\mathbf{x}$ quanto o ponto mais distante em $\mathcal{V}_k(\mathbf{x})$. Para prever a classe de $\mathbf{x}$, resta apenas procurar o rótulo mais comum em $\mathcal{V}_k(\mathbf{x})$. Ou seja, a regra de classificação do k -NN é


$$h(\mathbf{x}) = \text{moda}([y' : (\mathbf{x}', y') \in \mathcal{V}_k(\mathbf{x})]), \quad (3.2)$$

em que a função $\text{moda}(\cdot)$ retorna a ocorrência mais comum. Essa regra de classificação é comumente conhecida como *votação majoritária*. A Figura 3.1 ilustra a predição do método k -NN.

Resumo do classificador k -NN. Dado o conjunto $\mathcal{D} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$, o rótulo para um vetor qualquer $\mathbf{x}$ poder ser estimado com k -NN seguindo os seguintes passos:

1. compute $d_n := d(\mathbf{x}, \mathbf{x}_n)$ para $n = 1 \dots N$;
2. ache os índices $v_1, \dots, v_k$ dos k menores elementos de $\mathbf{d} = [d_1, \dots, d_N]$;
3. retorne $\hat{y} = h(\mathbf{x}) = \text{moda}(y_{v_1}, \dots, y_{v_k})$.

Figura 3.1: Exemplo do k NN em um problema de classificação binária, com $k = 3$. A classe associada a $\mathbf{x}$ é 1.



3.1.1 k -NN para regressão

O k -NN pode também ser empregado em problemas de regressão. Para isso, precisamos de uma forma de combinar as saídas em $\mathcal{V}_k(\cdot)$. Uma das estratégias mais comuns consiste em computar a média ponderada pelo inverso da distância:

$$h(\mathbf{x}) = \frac{1}{Z} \sum_{(\mathbf{x}', y') \in \mathcal{V}_k(\mathbf{x})} \frac{1}{d(\mathbf{x}', \mathbf{x})} y', \quad \text{com} \quad Z := \sum_{(\mathbf{x}', y') \in \mathcal{V}_k(\mathbf{x})} \frac{1}{d(\mathbf{x}', \mathbf{x})}, \quad (3.3)$$

permitindo que pontos mais próximos a $\mathbf{x}$ exerçam maior influência no cálculo da predição $h(\mathbf{x})$. Ideia semelhante pode também ser aplicada a classificação.

Observe que o algoritmo k -NN não necessita de treinamento, ou equivalentemente, o treinamento consiste em simplesmente armazenar o conjunto de dados $\mathcal{D}$. Por conta disso, k -NN é dito ser uma abordagem de *lazy learning* (Atkeson et al., 1997).

3.1.2 Qual distância utilizar?

Até então, descrevemos o k -NN sem especificar exatamente o formato da função de distância d . No entanto, a escolha de uma distância apropriada pode ser crítica para o sucesso do método. Por exemplo, se os dados de entrada estão dispostos na superfície do globo terrestre, gostaríamos de usar uma distância que considere a curvatura da terra (e.g., a distância esférica).


No entanto, raramente temos esse tipo de conhecimento sobre $\mathcal{X}$ e as escolhas mais comuns para d incluem casos particulares da distância de Minkowski:

$$d_p(\mathbf{x}, \mathbf{z}) = \|\mathbf{x} - \mathbf{z}\|_p := \left(\sum_{i=1}^D |x_i - z_i|^p \right)^{\frac{1}{p}}, \quad (3.4)$$

que para valores de $p = 1$ chama-se distância quarteirão ou *Manhattan*; $p = 2$ resulta na distância euclidiana; e $p \rightarrow \infty$ retorna o máximo da diferença entre as componentes dos vetores. A notação $\|\cdot\|_p$ é também chamada de norma L^p de um vetor.

A Figura 3.2 exemplifica o cálculo da norma L^p para vetores bidimensionais.

Uma possível deficiência de normas L^p é que elas não incorporam nenhuma informação sobre a distribuição $\mathbb{P}_{\mathbf{x}} : \mathcal{X} \rightarrow \mathbb{R}^+ \cup \{0\}$ — além do fato do suporte ser subconjunto dos reais.

Figura 3.2: Exemplos das normas L^1 , L^2 e L^∞ .

Por exemplo, se uma componente x_i tiver escala muito maior às demais $x_{j \neq i}$, ela pode dominar o cálculo da distância, ofuscando diferenças nas demais componentes $x_{j \neq i}$. Além disso, L^p são agnósticas a correlações entre componentes de $\mathbf{x} \sim \mathbb{P}_{\mathbf{x}}$. Uma alternativa para cobrir esses problema é utilizar a distância de Mahalanobis

$$d_M(\mathbf{x}, \mathbf{z}) := \sqrt{(\mathbf{x} - \mathbf{z})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \mathbf{z})}, \quad (3.5)$$

em que $\boldsymbol{\Sigma}$ é uma matriz de covariância. Uma escolha típica para $\boldsymbol{\Sigma}$ é a matrix de covariância amostral não-viesada dos dados de entrada, i.e.:

$$\boldsymbol{\Sigma} = \frac{1}{N-1} \sum_{n=1}^N (\mathbf{x}_n - \bar{\mathbf{x}})(\mathbf{x}_n - \bar{\mathbf{x}})^\top \quad (3.6)$$

$\bar{\mathbf{x}} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n$ é o vetor de médias amostrais. Observe que quando $\boldsymbol{\Sigma}$ é igual à matriz identidade, temos a distância euclidiana. Mas, afinal, *qual distância utilizar?* De modo geral, a menos que tenhamos profundo conhecimento sobre a geometria de $\mathcal{X}$, é impossível dar uma resposta direta. O melhor que podemos fazer é testar opções diferentes.

Normalização para média zero e variância um. Subtrair a média $\bar{\mathbf{x}} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n$ de cada vetor $\mathbf{x}_1, \dots, \mathbf{x}_N$ e, subsequentemente, multiplicá-los pela inversa da matriz diagonal $\mathbf{C}$ com entradas $C_{j,j} = \left(\sum_{i=1}^N (x_{i,j} - \bar{x}_j)^2 / (N-1) \right)^{1/2}$ é um procedimento comum em ML, sendo geralmente chamado de normalização ou padronização (*standardization*). Aplicar k -NN com $d(\mathbf{x}, \mathbf{z}) = \|\mathbf{x} - \mathbf{z}\|_2$ em dados transformados dessa maneira equivale a aplicar k -NN nos dados originais usando a distância de Mahalanobis com $\boldsymbol{\Sigma}^{-1} = \mathbf{C}^{-2}$.

Similaridade coseno. As distâncias estudadas até aqui são consideradas medidas de dissimilaridade entre vetores. De modo análogo, podemos definir a vizinhança de um ponto termos de medidas de similaridade. Uma importante medida de similaridade entre dois

vetores quaisquer $\mathbf{x}$ e $\mathbf{z}$ é dada pelo coseno do ângulo γ entre eles:

$$\cos(\gamma) = \frac{\mathbf{x}^\top \mathbf{z}}{\|\mathbf{x}\|_2 \|\mathbf{z}\|_2}.$$

A similaridade coseno é particularmente útil quando estamos interessados na orientação, e não na magnitude, dos vetores. Ela tem sido bastante utilizada em aplicações que envolvem dados textuais (Manning & Schütze, 1999). Note também que $\cos(\gamma)$ pode ser escrito como uma função do tipo $k(\mathbf{x}, \mathbf{z}) = \phi(\mathbf{x})^\top \phi(\mathbf{z})$, i.e., como uma generalização do produto interno entre $\mathbf{x}$ e $\mathbf{z}$. Medidas de similaridade que podem ser descritas dessa forma são chamadas funções de kernel.

Aprendendo métricas. Além de usar distâncias clássicas, como as L^p e a de Mahalanobis, é possível aprender métrica (ou pseudo-métrica) de distância de modo supervisionado, com base na taxa de classificação. Existe uma área de pesquisa em ML conhecida como aprendizado de métrica (*metric learning*) que se dedica a essa finalidade. Nesse nicho, um dos métodos mais é o chamado *large margin nearest neighbor* (Weinberger et al., 2006).

3.2 Maldição da dimensionalidade

A expressão *maldição da dimensionalidade* foi introduzida por Bellman (1957) e é comumente usada para descrever problemas causados pelo aumento exponencial do volume associado em função da dimensionalidade em espaços euclidianos. No caso do k -NN, esse aumento implica na esparsidade dos exemplos de treino, fazendo com que os k -vizinhos que procuramos estejam muito distantes.

Para ilustrarmos o efeito de alta dimensionalidade no k -NN, suponha que a distribuição $\mathbb{P}_{\mathbf{x}}$ sobre os vetores de entrada $\mathbf{x}_1, \dots, \mathbf{x}_N$ seja uniforme sobre uma hiper-bola D -dimensional S_D centrada na origem e com raio unitário. Suponha também queremos classificar o vetor origem $\mathbf{z} = (0, \dots, 0)^\top$. Seja r o raio da hiper-bola $S'_D \subseteq S_D$ que contém os k vizinhos mais próximos de $\mathbf{z}$. Em esperança, quão grande devemos esperar que seja r ? Primeiro note que a probabilidade de um vetor qualquer $\mathbf{x}_i \sim \mathbb{P}_{\mathbf{x}}$ estar em S'_D é igual a razão entre os volumes de S'_D e S_D , i.e.:

$$\mathbb{P}[\mathbf{x}_i \in S'_D] = \mathbb{E}_{\mathbf{x}_i \sim \mathbb{P}_{\mathbf{x}}} [\mathbb{1}_{\mathbf{x}_i \in S'_D}] = \frac{\pi^{D/2} r^D / \Gamma(\frac{D}{2} + 1)}{\pi^{D/2} 1^D / \Gamma(\frac{D}{2} + 1)} = r^D,$$

onde $\mathbb{1}_{\mathbf{x}_i \in S'_D}$ é uma função indicadora, assumindo 1 quando $\mathbf{x}_i$ toma valores em S'_D e 0 caso contrário. Segue, portanto, que o número esperado de amostras, dentre as N que possuímos, contidas em S'_D é $\sum_{i=1}^N \mathbb{E}_{\mathbb{P}_{\mathbf{x}}} [\mathbb{1}_{\mathbf{x}_i \in S'_D}] = Nr^D$. Então, para que tenhamos, em esperança, k pontos em S'_D , $Nr^D = k$. Isso implica que $r = \left(\frac{k}{N}\right)^{1/D}$ e, a medida que D cresce, temos:

$$\lim_{D \rightarrow \infty} r = \lim_{D \rightarrow \infty} \left(\frac{k}{N}\right)^{1/D} = 1.$$

Notavelmente, até para valores moderados de D , l pode ultrapassar 0.95, como é possível ver na Tabela 3.1. Isso vai contra a intuição motivadora de k -NN, pois os k vizinhos mais próximos podem estar tão longe quanto a casca da bola exterior S_D . Seria possível fugir dessa patologia caso obtivéssemos mais exemplos de treinamento? Infelizmente, não. Mantendo o raio $r \ll 1$ fixo, precisaríamos que N crescesse exponencialmente com D , i.e., $N \approx k(r/l)^D$. Além disso, para uma grande quantidade de exemplos, o k -NN pode se tornar computacionalmente proibitivo.

Tabela 3.1: Valor de r em função de D , para que S'_D tenha $k = 10$ das $N = 10^3$ amostras $\mathbf{x}_1, \dots, \mathbf{x}_N$ observadas (em esperança).

D	r
2	0.1
10	0.63
100	0.955
1000	0.9954

Manifolds de baixa dimensão. Na prática, não é incomum ver k -NN sendo utilizado espaços de alta dimensão, como de imagens, e atingindo boas taxas de acurácia. Uma explicação para esse fenômeno é que os dados não estão uniformemente distribuídos e, na verdade, residem em um subespaço de baixa dimensão. Por exemplo, suponha que $\mathcal{X} \subset \mathbb{R}^{256 \times 256 \times 3}$ é o espaço de imagens de tamanho 256×256 com três canais de cores — *red, green, and blue* (RGB) — que contém um gato. Nós esperamos que $\mathbb{P}_{\mathbf{x}}$ aloque massa zero para fotos de paisagens, obras de arte, etc.