

6. Inferência variacional

Similar à aproximação de Laplace, a ideia geral por trás de inferência variacional é aproximar uma distribuição complexa p — e.g., uma posteriori — com uma distribuição mais simples q . No entanto, ao invés de fazermos isso através de uma expansão de Taylor, escolhemos q dentro de uma família de distribuições Q de maneira a minimizar uma medida de *discrepância* para p . A mais popular dessas medidas é a chamada divergência de Kullback-Leibler (KL), definida para duas distribuições p e q como:

$$D_{\text{KL}}(q||p) = \mathbb{E}_{\boldsymbol{\theta} \sim q} \left[\log \frac{q(\boldsymbol{\theta})}{p(\boldsymbol{\theta})} \right] = \int_{\Theta} q(\boldsymbol{\theta}) \log \frac{q(\boldsymbol{\theta})}{p(\boldsymbol{\theta})} d\boldsymbol{\theta}. \quad (6.1)$$

6.1 Propriedades da divergência KL

Como vamos minimizar a divergência KL, alguns fatos são particularmente relevantes para nós. Primeiro, a divergência KL é não-negativa. Para verificar isso, basta notarmos que $-\log$ é uma função convexa e aplicarmos a desigualdade de Jensen na equação acima — $\phi(\mathbb{E}[x]) \leq \mathbb{E}[\phi(x)]$ para ϕ convexa. Segue, então, que:

$$D_{\text{KL}}(q||p) = \mathbb{E}_{\boldsymbol{\theta} \sim q} \left[-\log \frac{p(\boldsymbol{\theta})}{q(\boldsymbol{\theta})} \right] \geq -\log \underbrace{\mathbb{E}_{\boldsymbol{\theta} \sim q} \left[\frac{p(\boldsymbol{\theta})}{q(\boldsymbol{\theta})} \right]}_{\int_{\Theta} q(\boldsymbol{\theta}) \frac{p(\boldsymbol{\theta})}{q(\boldsymbol{\theta})} d\boldsymbol{\theta} = 1}. \quad (6.2)$$

Além disso, $D_{\text{KL}}(q||p)$ é zero somente se $q = p$. Para verificar esse fato, basta verificarmos as condições de optimalidade de primeira ordem para que q seja um mínimo para $D_{\text{KL}}(q||p)$. Por simplicidade, considere o caso em que tanto p quanto q são distribuições categóricas com d possíveis valores e, portanto, pode ser tratadas como um par de vetores d -dimensionais, i.e.:

$$\begin{aligned} q^* &= \arg \min_{q \in \mathbb{R}^d} && \sum_{i=1}^d q_i \log \frac{q_i}{p_i} \\ \text{sujeito a:} &&& \sum_{i=1}^d q_i = 1 \\ &&& q_i \geq 0 \quad \forall i = 1 \dots d \end{aligned} \quad (6.3)$$

Aplicando as condições de KKT, concluímos que é necessário que, para todo $i = 1 \dots d$:

$$\frac{\partial \sum_{j=1}^d q_j \log \frac{q_j}{p_j}}{\partial q_i} + \mu_i \frac{\partial - q_i}{\partial q_i} + \lambda \frac{\partial \left(\sum_{j=1}^d q_j \right) - 1}{\partial q_i} = 0 \quad (6.4)$$


$$\Rightarrow \frac{\partial q_i \log \frac{q_i}{p_i}}{\partial q_i} + \mu_i \frac{\partial - q_i}{\partial q_i} + \lambda \frac{\partial q_i - 1}{\partial q_i} = 0 \quad (6.5)$$

$$\Rightarrow 1 + \log q_i - \log p_i - \mu_i + \lambda = 0 \quad (6.6)$$

$$\Rightarrow q_i = p_i e^{-(1+\lambda-\mu_i)} \quad (6.7)$$

Pela condição de folgas complementares, μ_i deve ser 0 a não ser que $q_i = 0$. Seguindo Equação 6.7, $q_i = 0$ somente se $p_i = 0$. Para todo outro valor de p_i , q_i deve ser não zero — implicando $\mu_i = 0$. Concluímos então que o vetor q deve ser proporcional a p . Como ambos são vetores de probabilidade, isso significa que eles devem ser idênticos.

Divergência KL forward vs reverse É importante notar que, de forma geral, a divergência KL não é simétrica — i.e., $D_{KL}(p||q) \neq D_{KL}(q||p)$. Na literatura de ML, é comum chamar $D_{KL}(q||p)$ de divergência KL reversa. Conversamente, $D_{KL}(p||q)$ é conhecida como a divergência forward. Empiricamente, é bem estabelecido que minimizar a divergência reversa costuma resultar em resultados que focam em alguma(s) modas. Por outro lado, minimizar a divergência forward costuma promover aproximações que cobrem melhor o suporte de p . A figura abaixo ilustra esse fenômeno com $p(\theta) = 1/2 \mathcal{N}(\theta|3, 1) + 1/2 \mathcal{N}(\theta|-3, (1/2)^2)$ e q sendo Gaussiana univariada.



Vale ressaltar, que calcular o ELBO para $D_{KL}(p||q)$ envolve calcular esperanças sob a distribuição p , o que pode ser desafiador quando p é uma posteriori.

6.2 Cota inferior na log-evidência

No contexto de inferência Bayesiana, p costuma ser a posteriori $p(\theta|\mathcal{D})$, que desejamos aproximar. Então, substituindo p na Equação 6.1 por $p(\theta|\mathcal{D})$, obtemos:

$$D_{KL}(q(\theta)||p(\theta|\mathcal{D})) = \mathbb{E}_{\theta \sim q} [\log q(\theta)] - \mathbb{E}_{\theta \sim q} [\log p(\theta, \mathcal{D})] + \log p(\mathcal{D}), \quad (6.8)$$

onde $\log p(\theta, \mathcal{D})$ pode ser escrito como $\log p(\theta) + \log p(\mathcal{D}|\theta)$.

Como $\log p(\mathcal{D})$ é constante, definindo $-L(q) = \mathbb{E}_{\theta \sim q} [\log q(\theta)] - \mathbb{E}_{\theta \sim q} [\log p(\theta, \mathcal{D})]$, temos:

$$\hat{q} = \arg \min_{q \in Q} D_{\text{KL}}(q \| p) = \arg \max_{q \in Q} L(q). \quad (6.9)$$

Em outras palavras, minimizar a divergência KL é equivalente a maximizar L . Segue também da não-negatividade da divergência KL e da Equação 6.8 que

$$\underbrace{-(\mathbb{E}_{\theta \sim q} [\log q(\theta)] - \mathbb{E}_{\theta \sim q} [\log p(\theta, \mathcal{D})])}_{L(q)} \leq \log p(\mathcal{D}). \quad (6.10)$$

Vale mencionar que $p(\mathcal{D})$ é comumente conhecido como evidência. Nesse âmbito, L é uma cota inferior no logaritmo da evidência. No entanto, L é popularmente conhecida como Evidence Lower Bound (ELBO).

6.3 Lidando com ELBO intratável

Com relação à escolha de Q , costuma-se adotar uma família de distribuições paramétricas. Deste modo, podemos maximizar L sobre um espaço de parâmetros Ω . Por exemplo, se Q é o conjunto das distribuições Gaussianas univariadas, $\Omega = \mathbb{R} \times \mathbb{R}^+$ e $\omega \in \Omega$ é um par média/variação. De maneira geral, os termos envolvidos no ELBO podem ser intratáveis e, até meados da década passada, desenvolver soluções customizadas para posterioris diferentes era considerado uma contribuição técnica em ML.

Atualmente, existem metodologias genéricas, que viabilizam inferência variacional quase como uma tecnologia *off-the-shelf*. A mais famosa dentre essas, é o truque reparametrização. Essa técnica assume que é possível descrever a amostragem de $\theta \sim q$ a partir de uma transformação g de uma variável aleatória auxiliar ϵ . Além disso, precisamos que g seja diferenciável com respeito aos parâmetros ω de q . Por exemplo, se q é uma distribuição normal com parâmetros $\omega = (\mu, \sigma^2)$, podemos obter uma amostra $\theta \sim q$ definindo $g(\epsilon; \omega = (\mu, \sigma^2)) = \epsilon\sigma + \mu$ e amostrando ϵ de numa gaussiana padrão — i.e., com média zero e variação um.

Com isso, podemos aproximar os termos do ELBO com M amostrar M variáveis auxiliares $\epsilon^{(1)}, \dots, \epsilon^{(M)}$ e estimar o gradiente de $L(q)$ com respeito a ω como:

$$\nabla_{\omega} L(q) \approx \nabla_{\omega} \frac{1}{M} \sum_{m=1}^M \log p(\mathcal{D} | \theta^{(m)}) + \log p(\theta^{(m)}) - \log q(\theta^{(m)}), \quad (6.11)$$

onde $\theta^{(m)} = g(\epsilon^{(m)}; \omega)$ — note que, na notação acima, q também depende diretamente de ω . Em posse dessa estimativa, podemos utilizar nosso algoritmo de gradiente preferido para otimizar o ELBO. Naturalmente, essa aproximação deve ser refeita com novas amostras a cada passo de gradiente. Para evitar incluir restrições explícitas para garantir que parâmetros restritos sejam válidos (e.g., variações devem ser não-negativas), nós também as modelamos como a transformação de uma variável real. No caso citado acima, podemos ter $\omega = (\mu, \sigma^2 = u(z))$ com $u(z) = e^z$ ou $u(z) = \beta^{-1} \log(1 + e^{\beta z})$ para algum $\beta > 0$.

Uma outra técnica que pode ser utilizada quando não conhecemos uma reparametrização para q é a chamada REINFORCE, que decorre direto da identidade $\nabla_{\omega} q(\theta) = q(\theta) \nabla_{\omega} \log q(\theta)$.

Mais especificamente, para qualquer função real f , podemos escrever:

$$\nabla_{\omega} \mathbb{E}_{\boldsymbol{\theta} \sim q}[f(\boldsymbol{\theta})] = \nabla_{\omega} \int_{\Theta} f(\boldsymbol{\theta}) q(\boldsymbol{\theta}) d\boldsymbol{\theta} \quad (6.12)$$

$$= \int_{\Theta} f(\boldsymbol{\theta}) \nabla_{\omega} q(\boldsymbol{\theta}) d\boldsymbol{\theta} \quad (6.13)$$

$$= \int_{\Theta} q(\boldsymbol{\theta}) f(\boldsymbol{\theta}) \nabla_{\omega} \log q(\boldsymbol{\theta}) d\boldsymbol{\theta} \quad (6.14)$$

$$= \mathbb{E}_{\boldsymbol{\theta} \sim q}[f(\boldsymbol{\theta}) \nabla_{\omega} q(\boldsymbol{\theta})] \quad (6.15)$$

A REINFORCE é particularmente útil para distribuições sobre variáveis discretas, e é amplamente utilizada na literatura de aprendizado por reforço (*reinforcement learning*).

Apesar do truque poder ser usado para variáveis contínuas, o truque da reparametrização é tipicamente preferido na literatura de ML probabilístico. No entanto, existe pouca evidência formal sobre quando um é de fato melhor que o outro (e.g., Mohamed et al., 2020; Xu et al., 2019)